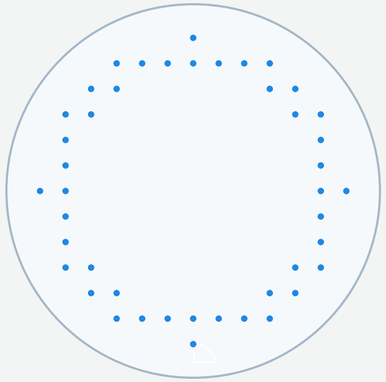
Wafer Map Defect Analysis

Process Root Cause Study



조장　전제현

조원　곽대현 · 김규민 · 박재호

Outline

1. Project introduction

2. 웨이퍼 맵 패턴과 분석 프레임

3. 8개 공정별 원인 가설·검증·개선

4. 공정 간 비교 및 예상 결과

5. 예상 한계와 목표

Project Objective

웨이퍼 맵의 **결함 분포 패턴**을 분석하고 모델의 예측 오류를 파악하여 **분류 성능을 개선**한다.
또한 공정별 물리적 이론과 수식을 바탕으로 **결함 발생 원인**을 분석하고,
관련 데이터와 연결하여 **개선 방향을 제시**하는 분석 모델을 구축한다.

1

분석 대상 (Wafer Map)

Center / Donut / Edge-Loc / Edge-Ring / Loc / Random / Scratch / Near-full

2

모델 성능 분석 (Model Performance)

분류 성능을 평가하고 오분류 사례와 오류 발생 특성을 분석

3

공정 범위 (Process Group)

Photo / Etch / Ion Implantation / Metal Wiring / Deposition / CMP / Cleaning / Oxidation

4

이론 기반 원인 분석 (Theory-based Root Cause Analysis)

공정별 물리적 메커니즘과 이론 수식 활용해 결함 발생 원인 가설을 도출하고 웨이퍼 맵 패턴과 연계

5

데이터 검증 및 모델 확장 (Data-driven Validation)

논문 사례와 공정·측정 데이터의 확보 가능성을 검토하고 원인 가설 및 개선 방향을 분석 모델에 반영

Our Plan & Expected Outcome

최종 목표: 웨이퍼 맵의 결함 패턴을 다각적으로 분석하고, 공정별 원인 후보와 개선 방향을 제시하는 분석 모델 구축

1

오늘 할 일 | 모델 성능 향상 및 오류 원인 정리

모델의 분류 성능을 개선하고, 오분류가 어떤 결함 패턴에서 발생하는지 단순 서술로 정리한다.

2

다음 주 | 실제 논문 사례 분석 및 데이터 탐색

논문에 보고된 결함 사례와 원인 분석 방법을 조사하고, 관련 공정·측정 데이터를 확보할 수 있는지 확인한다.
또한 각 공정에 대한 발생 원인을 수식, 이론 등으로 접근하여 해석한다.

3

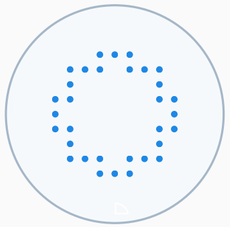
최종 목표 | 다각적 관점의 Wafer Map 분석 모델

웨이퍼 맵 패턴과 공정 메커니즘, 문헌 근거 및 추가 데이터를 연결해 결함 원인 후보와 개선 방향을 분석한다.

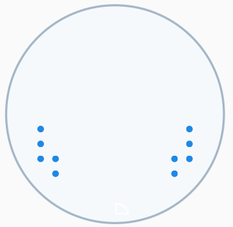
Wafer Map Patterns | Spatial Distribution



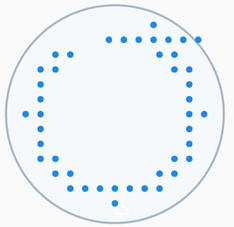
Center
중앙부 집중



Donut
중간 반경 링



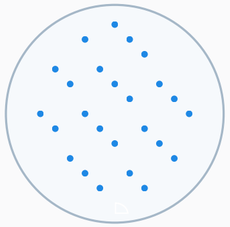
Edge-Loc
에지 일부 구간



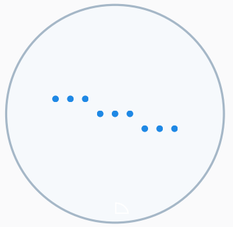
Edge-Ring
에지 원형 링



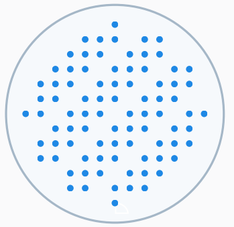
Loc
국소 군집



Random
불규칙 분포



Scratch
선형 결함



Near-full
전면적 불량

Photo | 포토리소그래피

탐구 초점 PR 코팅·노광·현상·EBR의 균일도와 오염을 확인

Pattern	원인 가설 (3)	제안 조치 (구체 항목)	검증 항목
CENTER	• 스핀 코팅 후 PR 두께의 중심부 편차 • 중심부 Focus·Dose 또는 레벨링 편차 • PEB·현상 조건의 위치별 불균일	• 회전속도·가속도·토출량·점도 확인 • Focus/Dose/Leveling 맵 확인 및 FEM으로 조건 최적화 • PEB 온도·시간, 현상액 유량·시간 점검	• PR 두께 맵과 중심부 편차 • 중심/주변부 CD-SEM 및 Focus/Dose 맵 • PEB 온도 맵·현상 로그
DONUT	• 중간 반경 PR 두께 편차 • Focus·Dose의 반경 방향 편차 • PEB·현상 균일도 저하	• 회전속도·가속도·토출량·점도 점검 • Focus/Leveling 맵 확인, FEM으로 조건 재설정 • PEB 온도·시간 및 현상액 유량 점검	• 반경별 PR 두께 맵 • 중간 반경 CD-SEM + Focus/Dose 맵 • PEB 온도·현상 로그
EDGE-RING	• Edge Bead 또는 EBR 이상 • 가장자리 Focus·Leveling 오차 • 가장자리 접착·현상 문제	• EBR 폭·노즐 위치·용매 유량·시간 점검 • 가장자리 보정값과 CD 비교 • 표면 오염·접착처리·현상/린스 점검	• 가장자리 PR 두께·EBR 폭 • Edge vs. center CD-SEM • 잔류 PR·박리·오염 검사
RANDOM	• PR·노즐·모듈 파티클 • 코팅 기포·국부 현상 결함 • 핫플레이트·핸들링의 간헐 이상	• 필터·노즐·컵·현상 모듈 오염 점검/청소 • 토출·현상 유량과 시간을 확인 • 핫플레이트 균일도·척/로봇 접촉부 점검	• 코팅 전후·현상 후 파티클 맵 • PR 두께·CD 및 잔류 패턴 • 로트/장비별 결함률, 조치 전후 비교
SCRATCH	• 로봇·척 접촉에 의한 손상 • 코팅·현상 모듈 내 이물/접촉 • 선형 오염 또는 패턴 전사 결함	• 로봇 핸드·척·핀 마모/이물 및 경로 확인 • 노즐·모듈 내부 접촉 가능성 점검 • 공정 단계별 검사로 최초 발생 시점 추적	• 현미경/표면 검사로 실제 흠집 확인 • 코팅 전후·노광/현상 후·식각 후 검사 • 웨이퍼 간 방향·좌표 반복성 비교

핵심 데이터: PR 두께 맵 · CD-SEM · Focus/Dose/Leveling · EBR · 파티클/표면 검사 · 장비/로트 이력

Etch | 식각

탐구 초점 플라즈마·가스 분포·에지 링·챔버 잔류물 확인

Pattern	원인 가설 (3)	제안 조치 (구체 항목)	검증 항목
CENTER	• 중심부 플라즈마·이온 에너지 분포 편차 • 중심부 반응성 가스 농도 및 식각 속도 편차 • 중심부 웨이퍼 온도·부산물 배출 조건 불균일	• RF Power·Bias·가스 유량 및 압력 점검 • 플라즈마 분포와 중심·주변부 식각 속도 비교 • 척 온도·Backside He 냉각·챔버 상태 확인	• 식각 전후 막 두께 및 Etch Rate 맵 • 중심부·주변부 잔류막 및 CD 비교 • RF·압력·가스 유량·온도 로그
DONUT	• 특정 반경의 플라즈마·이온 에너지 분포 편차 • 반경별 반응성 라디칼 공급 및 소모 차이 • 웨이퍼 온도 또는 부산물 배출의 반경 방향 불균일	• RF Power·압력·가스 유량 및 분포 조건 점검 • 반경별 식각 속도와 잔류막 두께 비교 • 척 온도·냉각 조건 및 챔버 세정 상태 확인	• 반경별 Etch Rate·막 두께 맵 • 중간 반경 CD·잔류막 및 단면 프로파일 • 플라즈마·온도·공정 조건 로그
EDGE-RING	• 웨이퍼 가장자리 플라즈마·이온 에너지 분포 편차 • 가장자리 반응성 가스 공급 및 부산물 배출 차이 • 가장자리 온도·시스 전기장 및 식각 속도 불균일	• 가장자리 RF·가스 분포 및 압력 조건 점검 • Edge·Center 식각 속도와 CD 비교 후 조건 최적화 • 척 가장자리·Edge Ring 부품 마모 및 온도 상태 점검	• 가장자리·중심부 Etch Rate 및 막 두께 • Edge vs. Center CD-SEM·단면 분석 • Edge Ring 상태·온도·가스·RF 로그
RANDOM	• 챔버 파티클 또는 벽면 부산물 박리 • 식각 부산물 재부착 및 국부 잔류막 발생 • 패턴 밀도 차이에 따른 Microloading·ARDE	• 챔버·전극·부품의 파티클 및 박리 상태 점검·세정 • 가스 조성·유량·압력 및 부산물 배출 조건 확인 • 패턴 밀도·종횡비별 식각 조건과 오버에치 검토	• 식각 전후 파티클·표면 결함 맵 • 잔류막·부산물 및 국부 CD 검사 • 패턴 밀도·종횡비별 Etch Rate·결함률 비교
SCRATCH	• 챔버 벽면 부산물 박리 및 선형 재부착 • 웨이퍼 이송·척 접촉부의 기계적 손상 • 특정 방향으로 이어진 마스크 손상·패턴 결함	• 챔버 벽·전극·Edge Ring의 박리 및 부착물 점검 • 로봇 핸드·척·핀의 마모·이물 및 이송 경로 확인 • 식각 전후 검사로 최초 발생 공정과 방향성 추적	• 광학 현미경·표면 검사로 실제 스크래치 여부 확인 • 식각 전후 결함 맵 및 CD·단면 프로파일 비교 • 웨이퍼 간 결함 좌표·방향·장비별 반복성 분석

핵심 데이터: PR 두께 맵 · CD-SEM · Focus/Dose/Leveling · EBR · 파티클/표면 검사 · 장비/로트 이력

Ion Implantation | 이온 주입

탐구 초점 **빔 스캔·도즈·에너지·웨이퍼 정렬의 균일도 확인**

Pattern	원인 가설 (3)	제안 조치 (구체 항목)	검증 항목
CENTER	• 중심부 빔 전류 밀도·도즈 분포 편차 • 중심부 스캔 중첩 및 빔 주사 조건 불균일 • 중심부 시트 저항 측정값 또는 도핑 활성화 편차	• 빔 전류·도즈 교정 상태 확인 • 빔 스캔 조건과 중심·주변부 도즈 비교 • 주입 후 열처리 조건과 웨이퍼 온도 이력 확인	• 도즈 및 시트 저항 맵 • 중심부·주변부 도핑 농도 비교 • 빔 전류·스캔·열처리 로그
DONUT	• 특정 반경에서 빔 스캔 중첩 불균일 • 반경별 도즈 전달량 차이 • 특정 위치의 웨이퍼 온도 또는 후속 활성화 편차	• 스캔 궤적·스캔 속도·빔 전류 점검 • 반경별 도즈 및 면저항 분포 비교 • 웨이퍼 냉각·열처리 균일도 확인	• 반경별 도즈·시트 저항 맵 • 동일 반경의 반복 결함 여부 • 스캔 및 온도 로그
EDGE-RING	• 웨이퍼 가장자리의 빔 조사량 편차 • 가장자리 빔 주사·웨이퍼 이동 조건 불균일 • 가장자리 측정·열처리 조건에 따른 전기적 특성 편차	• 웨이퍼 가장자리의 빔 조사량 편차 • 가장자리 빔 주사·웨이퍼 이동 조건 불균일 • 가장자리 측정·열처리 조건에 따른 전기적 특성 편차	• 빔 스캔 범위와 도즈 보정 상태 확인 • Edge와 Center의 도즈·면저항 비교 • 웨이퍼 지지·냉각 및 열처리 조건 확인
RANDOM	• 웨이퍼 표면 파티클 또는 오염 • 국부적인 마스크·산화막 상태 차이에 따른 주입 차단 편차 • 측정 장비의 접촉·측정 오류	• 주입 전후 표면 결함 및 오염 검사 • 마스크·스크린 산화막 두께와 상태 확인 • 면저항 측정 장비 교정 및 재측정	• 표면 결함 맵 및 광학 검사 • 산화막 두께·마스크 상태 측정 • 재측정 결과와 결함 좌표 비교
SCRATCH	• 웨이퍼 이송·척 접촉에 의한 선형 손상 • 마스크 또는 표면막의 선형 손상·오염 • 측정 과정에서 발생 또는 선형 측정 디펙	• 로봇 핸드·척·웨이퍼 접촉부 점검 • 주입 전후 표면 검사로 최초 발생 공정 추적 • 광학 검사와 전기적 맵을 대조해 실제 결함 여부 확인	• 주입 전후 광학 결함 맵 • 스크래치 방향·좌표의 웨이퍼 간 반복성 • 시트 저항 맵과 표면 결함 위치 비교

핵심 데이터: PR 두께 맵 · CD-SEM · Focus/Dose/Leveling · EBR · 파티클/표면 검사 · 장비/로트 이력

Metal Wiring | 금속 배선

탐구 초점 금속 두께·패턴 전사·잔류 금속·비아 접촉 확인

Pattern	원인 가설 (Excel)	제안 조치 (Excel)	검증 항목 (Excel)	Ref.
Center	금속 증착 또는 패턴 식각의 중앙부 균일도 저하	증착 두께와 식각 균일도를 확인하고 레시피 보정	금속 두께·저항 맵	S1
Donut	금속 막 또는 도금 두께가 중간 반경에서 변함	증착/도금 유량과 전류 분포를 점검	금속 두께·저항의 반경 프로파일	S1
Edge-Ring	금속 증착·도금·식각의 에지 효과로 원형 결함	에지 전류/막 두께 균일도와 에지 클리닝 확인	금속 두께·저항·브리지 검사	S1
Random	금속 파티클이나 박리 조각이 임의 위치에 부착	챔버 부품 청소와 증착 전 파티클 검사	금속 공정 전후 파티클 맵	S4
Scratch	금속 공정 전후 이송 중 표면 접촉 또는 입자 끌림	로봇 엔드이펙터·척·이송 레시피 확인	금속 공정 전후 맵 비교	S4

핵심 검증 데이터

금속 두께·저항 맵, 단락/단선 검사, 결함 좌표

예상되는 결과

결함 좌표와 공정 측정값의 공간적 일치 여부를 확인해 원인 후보의 우선순위를 정하고, 개선 전후 결함률·균일도 변화를 비교한다.

Deposition | 박막 증착

탐구 초점 가스 분포·막 두께·챔버 부품 박리와 파티클 확인

Pattern	원인 가설 (Excel)	제안 조치 (Excel)	검증 항목 (Excel)	Ref.
Center	챔버 내 가스 흐름 또는 증착률이 중심부에서 비정상	가스 유량·분배판·챔버 상태를 점검하고 균일도 측정	막 두께 맵, 챔버 간 비교	S1
Donut	증착 두께가 중간 반경에서 링 형태로 달라짐	가스 분배와 웨이퍼-샤워헤드 간격을 점검	막 두께의 반경 프로파일	S1
Edge-Ring	에지에서 막 두께가 원형으로 치우침	웨이퍼 센터링, 샤워헤드 간격, 에지 가스 흐름 확인	전면 막 두께 맵	S4
Random	챔버에서 떨어진 입자가 임의 위치에 부착	챔버 벽면·샤워헤드 청소 및 파티클 모니터링	증착 전후 파티클 맵	S4
Scratch	로봇·척 접촉 또는 박리된 막 조각이 표면을 긁음	핸들러와 챔버 부품의 마모·박리 점검	스크래치 위치와 장비 접촉점 비교	S4

핵심 검증 데이터

막 두께 맵, 굴절률·접착 검사, 챔버 PM 이력

예상되는 결과

결함 좌표와 공정 측정값의 공간적 일치 여부를 확인해 원인 후보의 우선순위를 정하고, 개선 전후 결함률·균일도 변화를 비교한다.

CMP | 화학적 기계적 연마

탐구 초점 중심-에지 제거율·패드·슬러리·리테이닝 링 확인

Pattern	원인 가설 (Excel)	제안 조치 (Excel)	검증 항목 (Excel)	Ref.
Center	중앙부와 가장자리의 연마율 차이로 웨이퍼 중심에 불량이 집중	패드 컨디셔닝 상태와 압력 분포를 점검하고 공정 조건을 균일화	중심-가장자리 제거율 맵, 패드 상태	S2
Donut	패드 압력 또는 슬러리 분포가 중간 반경에서 달라짐	패드 컨디셔닝과 슬러리 분포를 조정	제거율의 반경 프로파일	S3
Edge-Ring	리테이닝 링 또는 에지 압력 분포가 불균일	링 상태·헤드 압력·패드 컨디셔닝 점검	에지 제거율과 칩핑 검사	S3
Random	슬러리 응집물 또는 패드 파편이 표면을 오염	슬러리 필터·혼합·공급 라인과 패드 컨디셔닝 점검	슬러리 입자 크기와 결함률	S3
Scratch	패드의 이물질 또는 슬러리 응집물이 표면을 긁음	슬러리 필터·패드 컨디셔닝·패드 교체 상태 점검	선형 스크래치와 CMP 공정 이력	S3

핵심 검증 데이터

제거율 맵, 스크래치 검사, 슬러리 입자·패드 상태

예상되는 결과

결함 좌표와 공정 측정값의 공간적 일치 여부를 확인해 원인 후보의 우선순위를 정하고, 개선 전후 결함률·균일도 변화를 비교한다.

Cleaning | 세정

탐구 초점 세정액·UPW·노즐·브러시·건조 중 재부착 확인

Pattern	원인 가설 (Excel)	제안 조치 (Excel)	검증 항목 (Excel)	Ref.
Center	세정액 흐름이나 건조가 중심부에 잔류물·입자를 남김	노즐, 유량, 린스 및 건조 조건을 점검	표면 입자·잔류물 검사	S3
Donut	세정·린스 유동이 특정 반경에 잔류물을 남김	노즐 위치, 회전, 유량을 확인	반경별 파티클·잔류물 검사	S3
Edge-Ring	에지에 세정액·입자·잔류물이 원형으로 남음	에지 린스와 건조, 회전 조건을 점검	전면/에지 입자 검사	S4
Random	클린룸 또는 세정액의 파티클이 불규칙하게 부착	필터·UPW·약액 청정도와 세정 장비 상태 점검	파티클 수와 약액/필터 이력	S3
Scratch	브러시 또는 접촉 부품에 입자가 끼어 긁힘 발생	브러시 마모·세정 헤드·접촉 압력을 점검	스크래치 방향과 장비 접촉 방향	S4

핵심 검증 데이터

세정 전후 파티클 맵, 잔류물·워터마크 검사

예상되는 결과

결함 좌표와 공정 측정값의 공간적 일치 여부를 확인해 원인 후보의 우선순위를 정하고, 개선 전후 결함률·균일도 변화를 비교한다.

Oxidation | 산화

탐구 초점 온도·가스·웨이퍼 배치·오염에 따른 산화막 균일도 확인

Pattern	원인 가설 (Excel)	제안 조치 (Excel)	검증 항목 (Excel)	Ref.
Center	열처리 중 중심부 온도 또는 산화막 성장률 차이	온도 센서, 가스 흐름, 웨이퍼 배치 조건을 확인	산화막 두께 맵, 온도 균일도	S5
Donut	온도 분포에 중간 반경의 고리형 차이가 발생	히터 존과 온도 보정 상태를 점검	산화막 두께의 반경 프로파일	S5
Edge-Ring	웨이퍼 가장자리의 온도 또는 산화막 성장 차이	온도 균일도, 가스 흐름, 보트 위치를 확인	산화막 두께의 에지 프로파일	S5
Random	퍼니스 튜브/보트의 오염 입자가 웨이퍼에 전이	튜브·보트 청정도와 교체/세정 주기 점검	퍼니스 배치별 결함률	S5
Scratch	보트에 넣고 빼는 과정에서 웨이퍼 접촉	보트 슬롯과 로딩/언로딩 동작 점검	슬롯별 스크래치 반복성	S5

핵심 검증 데이터

산화막 두께 맵, 온도 프로파일, 전기 특성·오염 분석

예상되는 결과

결함 좌표와 공정 측정값의 공간적 일치 여부를 확인해 원인 후보의 우선순위를 정하고, 개선 전후 결함률·균일도 변화를 비교한다.

Summary

Pattern	Photo	Etch	Implant	Deposition	CMP	Cleaning	Oxidation
Center	코팅·노광	플라즈마·식각률	도즈 분포	막 두께	연마율	유동·건조	온도·성장률
Donut	반경별 PR/CD	반경별 식각률	반경별 도즈	반경별 두께	압력·슬러리	세정 유동	히터 존
Edge-Ring	EBR·에지 CD	에지 링·시스	에지 스캔	에지 가스·막	리테이닝 링	에지 린스	에지 온도
Random	파티클·환경	챔버 잔류물	소스·빔라인	챔버 박리	슬러리·패드	UPW·약액	퍼니스 오염
Scratch	핸들링·트랙	척·부품 접촉	클램프·로봇	로봇·척	슬러리 응집물	브러시·접촉부	보트 접촉

Limitations & Interpretation Rules

한계 1. 기본 데이터의 높은 예측 성능과 모델 개선의 어려움

기본 데이터만으로도 분류 성능이 매우 높으면 추가 데이터를 학습해도 성능 개선 폭이 작을 수 있어. 특히 기존 데이터와 추가 데이터의 수집 환경이나 분포가 다르면 성능이 오히려 낮아지거나 비슷함

한계 2. 서로 다른 출처의 데이터를 통합하기 어려움

논문, 공개 데이터셋, 공정 측정 자료에서 확보한 데이터를 하나로 합쳐 학습시키기 어려울 수 있어.

데이터 수집 과정에서 발생할 수 있는 한계

데이터 접근성

실제 반도체 공정의 장비 로그, 도즈·식각 속도·온도 데이터는 기업 내부 자료라 확보하기 어려움

검증 데이터 부족

새로운 공정이나 장비에서 수집한 독립 데이터가 부족해 실제 환경에서의 일반화 성능을 확인하기 어려움

Reference

ID	Reference (as listed in Excel)	URL
S1	Wafer map defect patterns and candidate causes (ScienceDirect, 2023)	https://www.sciencedirect.com/science/article/pii/S0957417423010461
S2	Wafer defect patterns and process relationships (Wiley, 2022)	https://onlinelibrary.wiley.com/doi/full/10.1155/2022/1829792
S3	Efficient mixed-type wafer defect pattern recognition (PMC, 2024)	https://pmc.ncbi.nlm.nih.gov/articles/PMC11279086/
S4	Wafer edge inspection and process defectivity (Semiconductor Engineering)	https://semiengineering.com/criticality-of-wafer-edge-inspection-and-metrology-data-to-all-surface-defectivity-root-cause-and-yield-analysis/
S5	Semiconductor fabrication overview and quality-control challenges (Thermo Fisher)	https://www.thermofisher.com/de/en/home/industrial/manufacturing-processing/manufacturing-processing-learning-center/electronics-information/semiconductor-analysis-imaging-metrology-information/semiconductor-fabrication-overview.html
S6	Wafer surface defect detection review (Electronics, 2023)	https://doi.org/10.3390/electronics12081787
S7	Wafer map pattern interpretation (WaferTools)	https://wafertools.github.io/wafermap/pattern-detection/

Project Objective | **연구 목표**

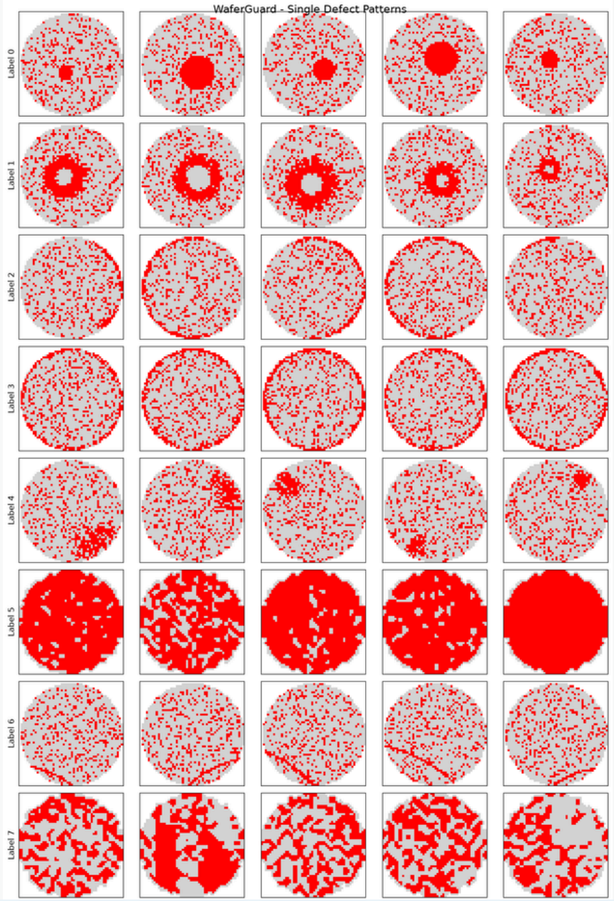
WaferGuard**에서 학습한** CNN**이** WM-811K **결함 분류에 얼마나 적응할 수 있는가**?

- WaferGuard 사전학습 모델의 WM-811K Zero-shot 성능 측정
- 특징 추출부 동결(Stage 1)과 일부 Conv Fine-tuning(Stage 2)의 성능 변화 확인
- WM-811K 단독 학습 Baseline과 동일 Test에서 비교
- 결함 유형별 오류 및 데이터셋 간 일반화 한계 분석

핵심 질문: **전이학습 과정에서 얼마나 개선되며**, Baseline **대비 경쟁력은 어떠한가**?

Wafer Map Patterns | 8 Defect Types

WM-811K의 8개 단일 결함 패턴과 WaferGuard의 8개 기본 결함 유형



- Center / Donut
- Edge-Loc / Edge-Ring
- Loc / Near-full
- Random / Scratch

두 데이터셋의 결함 이름은 유사하지만 이미지 분포와 라벨 체계는 동일하지 않음

Dataset Overview | 규모와 라벨 체계

WaferGuard

38,015

52×52 · 8개 결함 조합 · Multi-label

WM-811K

811,457

전체 웨이퍼 · 8개 결함 라벨 25,519개

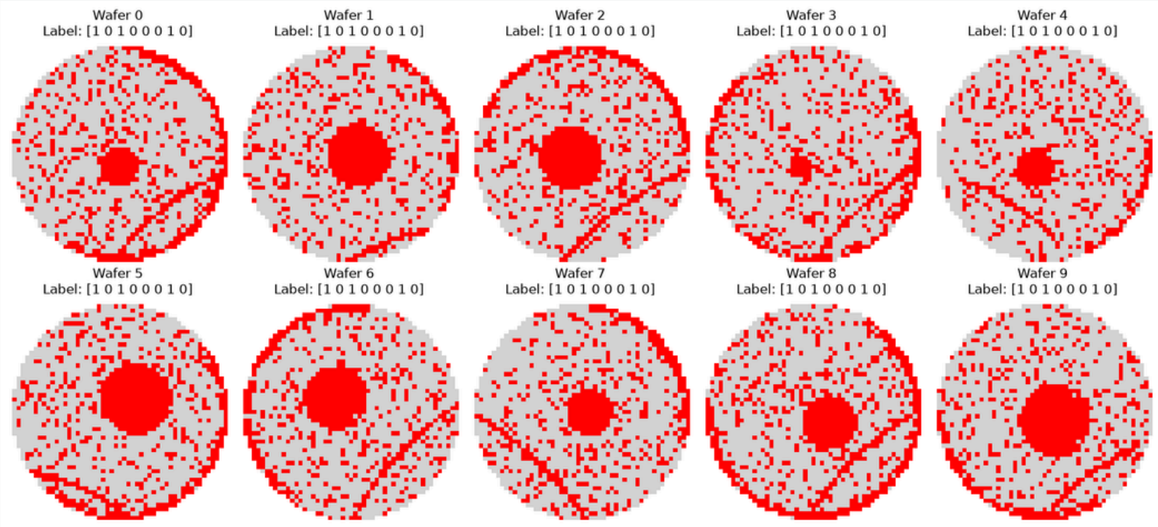
실제 모델 학습 비교에서는 전체 이미지 수가 아닌 라벨이 있는 결함 데이터를 기준으로 해석

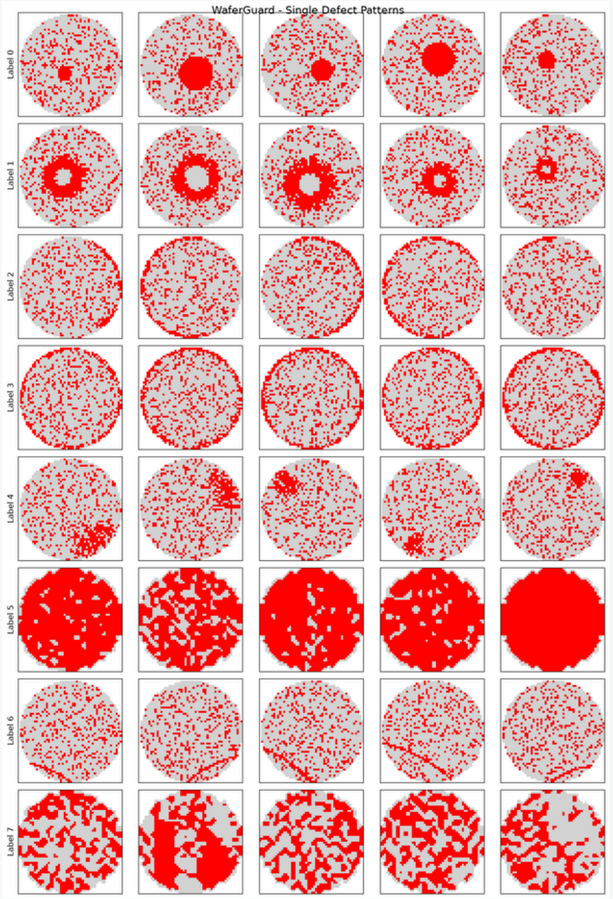
WM-811K: Training 17,625 / Test 7,894 | WaferGuard: 8개 결함의 다중 조합 포함

WaferGuard data: huggingface.co/datasets/oliversinn/waferguard-dataset | Original: Wang et al. (2020)

WaferGuard | **원본 데이터와 결함 조합**

Notebook에 기록된 실제 웨이퍼 맵 시각화

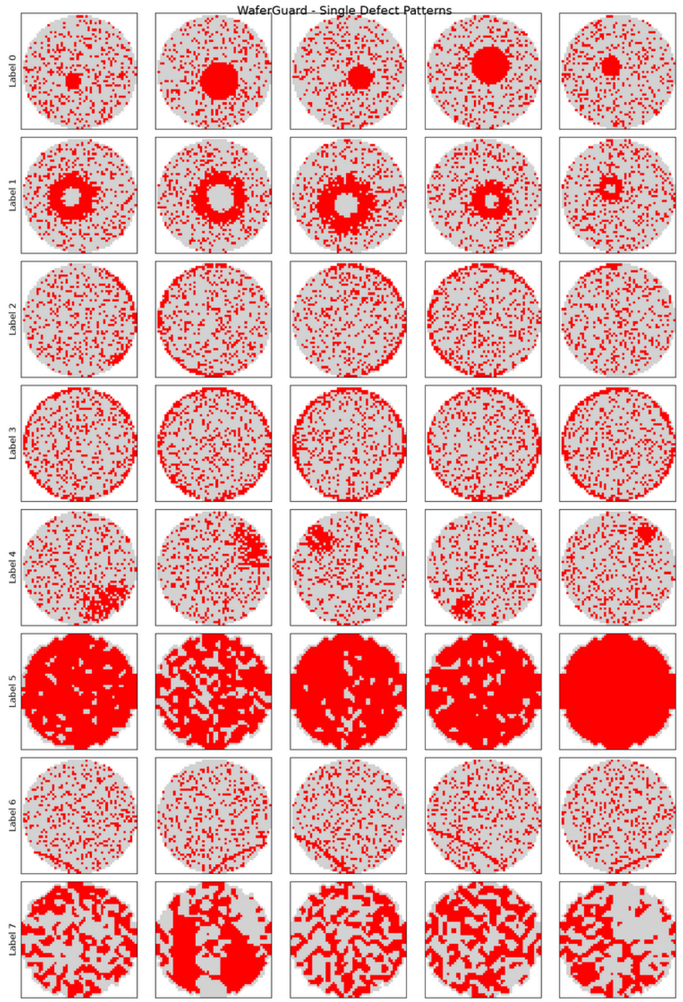




WaferGuard: Multi-label **학습을 통해 단일 및 복합 결함 패턴의 특징 추출**

WaferGuard | 단일 결함 샘플 추출과 라벨 확인

Notebook Cell 10 · 단일 결함 조건으로 8개 라벨별 5장씩, 총 40장 시각화



라벨 순서: 0 Center · 1 Donut · 2 Edge-Loc · 3 Edge-Ring · 4 Loc · 5 Near-full · 6 Scratch · 7 Random

단일 결함 선택 조건

```
labels[:, i] == 1
labels.sum(axis=1) == 1
```

무엇을 확인했나?

* 8개 라벨의 실제 공간적 결함 형태
* 복합 결함을 제외한 순수 단일 패턴 - 확인을 위해서
* WM-811K 라벨 대응을 위한 사전 점검

주의: 40개는 시각화용 샘플

사전학습 데이터 전체를 단일 라벨로 제한한 것은 아님

WaferGuard | Multi-label을 유지한 CNN 사전학습

단일 결함 시각화와 실제 학습 데이터 구성은 서로 다른 단계

단일 결함

7,015개

8차원 라벨 합 = 1

복합 결함

30,000개

8차원 라벨 합 ≥ 2

무결함

1,000개

8차원 라벨 합 = 0

사전학습: Multi-label **데이터** 38,015**개 전체 활용**

8차원 Multi-hot 라벨 유지 → Dense(8, Sigmoid) → Binary Cross-Entropy

단일 결함뿐 아니라 복합 결함과 무결함 샘플도 학습에 포함

WM-811K **전이학습**: **목표 데이터셋의** Single-label **구조에 맞게 출력층 교체**

사전학습 CNN 특징 추출부 재사용 → Dense(8, Softmax) → Sparse Categorical Cross-Entropy

핵심: **멀티라벨을 임의로 하나의 정답으로 바꾼 것이 아니라, 학습 단계별 출력 체계를 달리 설계**

WaferGuard | 학습 전 데이터 가공 과정

Notebook Cell 11–16 · 입력값 정리, 라벨 조합별 분할, 정규화 후 사전학습

01	**원본 로딩**	Parquet 2개 결합 · 이미지 (38,015, 52, 52) · 8차원 multi-hot
02	**예외 픽셀 처리**	희소한 픽셀값 3을 학습용 복사본에서 2로 치환 · 원본 보존
03	**라벨 조합 유지**	각 8비트 조합을 문자열로 변환해 38개 조합별 층화 분할
04	**데이터 분할**	Train 80% · Validation 10% · Test 10%
05	**입력 정규화**	0/1/2 픽셀값을 0~1 범위로 변환 · 채널 차원 추가
06	CNN **학습**	8 Sigmoid 출력 · Binary Cross-Entropy · Batch 64 · EarlyStopping

학습 목적: WaferGuard**의 다양한 결함 조합에서 특징을 추출하고**, **이후** WM-811K 8**종 단일 결함에 적응**

WaferGuard | Multi-label **라벨 구조와 변환**

Notebook: 38,015개 · 8차원 multi-hot · 단일/복합/무결함 샘플 공존

Single-label

7,015

활성 라벨 1개 · 단일 결함

Multi-label

30,000

활성 라벨 2개 이상 · 복합 결함

No defect

1,000

활성 라벨 0개 · 8종 외

WaferGuard **사전학습**: 8**개** Sigmoid **출력** + Binary Cross-Entropy

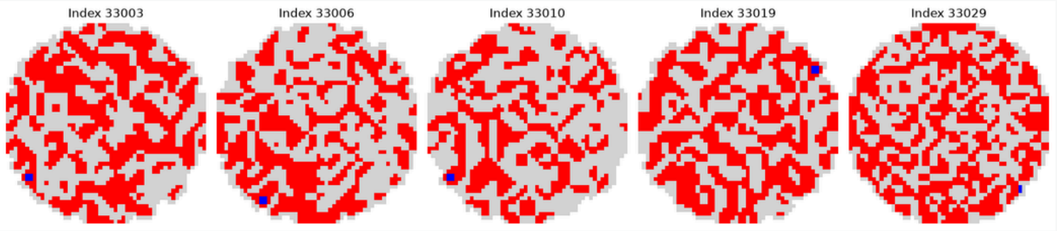
WM-811K 적응 학습: 특징 추출부 재사용 + 8개 Softmax 출력 + Sparse Categorical Cross-Entropy

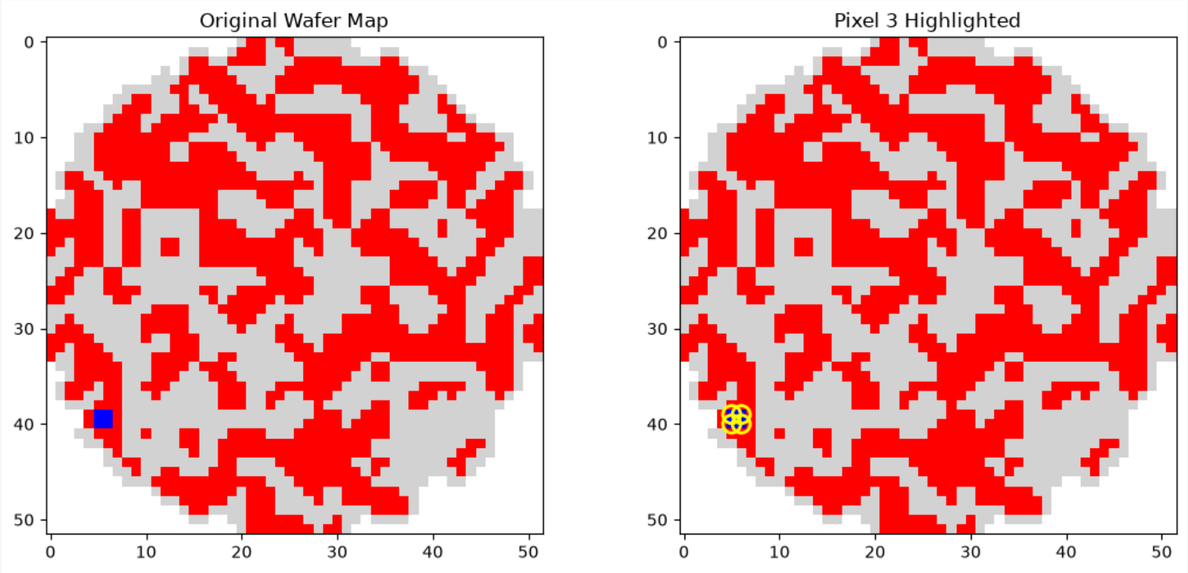
복합 결함을 임의로 하나의 정답으로 바꿔 사전학습한 것이 아니라, Multi-label 학습을 유지하고 분류 Head를 교체

라벨 인덱스: WaferGuard 6=Scratch, 7=Random → WM-811K 6=Random, 7=Scratch (**평가 시 교환**)

WaferGuard | **픽셀값 3 검출 및 예외 처리**

Notebook 전체 픽셀 검증 결과: 일반 값 0/1/2 외에 드문 값 3이 발견됨





Pixel 3: 214 pixels (**전체 약** 0.0002%) | 105 / 38,015 wafers (0.28%)

학습용 복사본에서 3 → 2**로 임시 치환 · 원본** X_wafer**는 보존 · 3의 물리적 의미는 검증되지 않음**

Data Harmonization | 두 데이터셋 입력 조건 통일

구분	WaferGuard 사전학습	WM-811K 전이학습 / 평가
입력 크기	52×52 원본	가변 크기 → 52×52 Nearest Neighbor
픽셀	0/1/2, 극소수 3	0/1/2
정규화	3 → 2 치환 후 / 2	/ 2 (0 / 0.5 / 1)
정답 라벨	8차원 multi-hot	8종 단일 class ID
분류기	Sigmoid · BCE	Softmax · Sparse CE

WaferGuard: 38**개 라벨 조합을 기준으로** Train 80% / Val 10% / Test 10% **층화 분리**

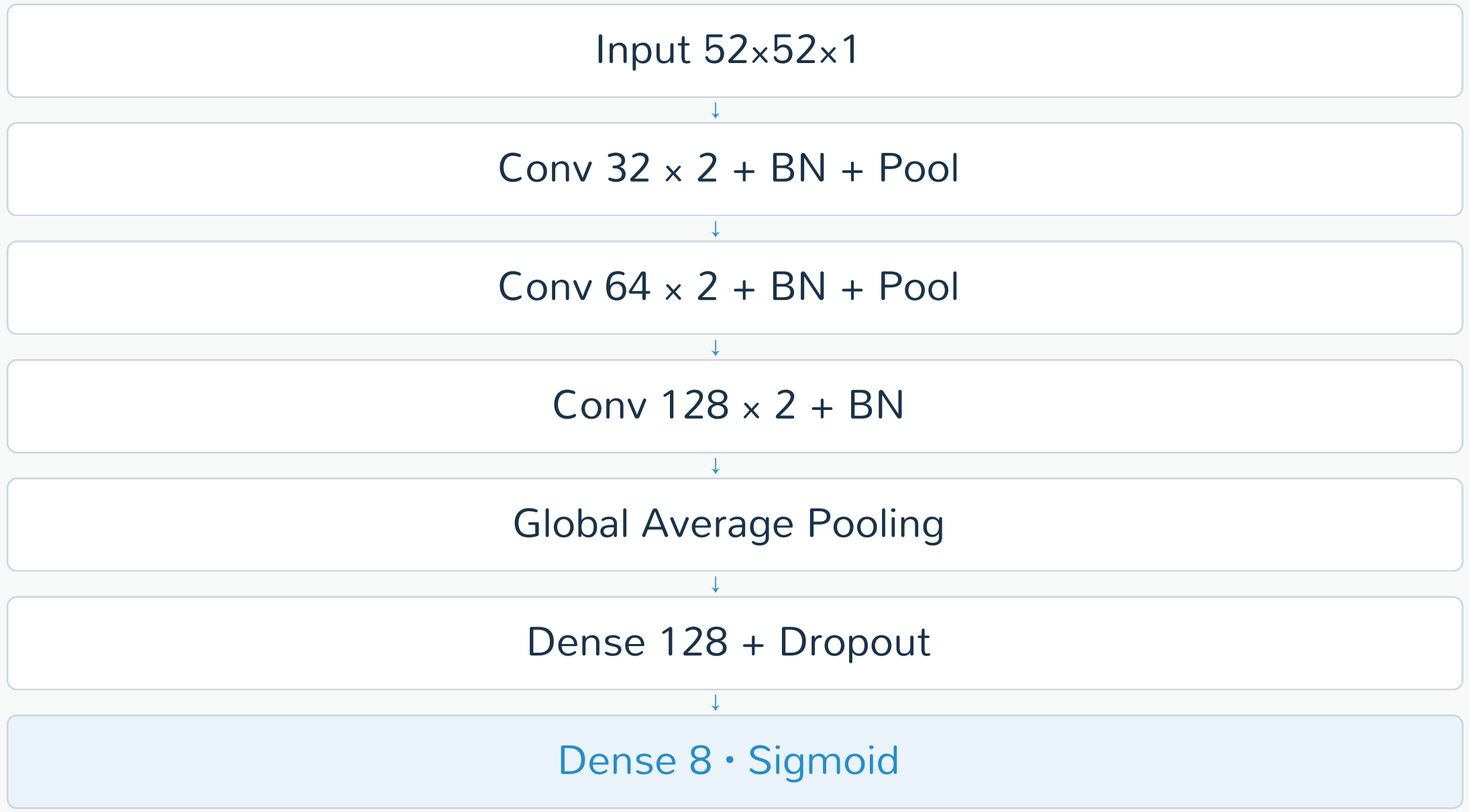
핵심: **두 데이터셋의 입력 표현은 통일하되, 원래 학습 목표**(Multi-label vs Single-label)**는 구분**

WM-811K | 전처리 및 평가 데이터 구성

01	**결함 8종 필터링**	failureType이 지정된 25,519개 사용
02	**입력 크기 통일**	원본 가변 크기 → 52×52 (Nearest-neighbor)
03	**픽셀 정규화**	0 / 1 / 2 → 0 / 0.5 / 1.0
04	**분할 기준**	원본 Test 7,894개 보존, Train 내부 Lot-disjoint 검증

주의: WaferGuard**의** Scratch / Random **출력 인덱스를** WM-811K **순서에 맞춰 재배열**

WaferGuard CNN | **사전학습 구조**



WaferGuard **사전학습**: Binary Accuracy 99.69%, AUC 0.9989 (WaferGuard **자체** Test **기준**)

Transfer Learning | **단계별 모델 설계**

A	Zero-shot	WaferGuard CNN 그대로 적용	WM-811K 학습 없음
B	Stage 1	CNN 특징 추출부 동결	WM-811K Dense 분류기 학습
C	Stage 2	마지막 Conv 2개 층 해제	저학습률 Fine-tuning
D	Baseline	무작위 초기화 CNN	WM-811K만으로 학습

모든 WM-811K **평가**: **동일한 독립** Test 7,894**개 사용**

Training Setup | **실험 조건 통일**

모델	Optimizer / Learning Rate	**학습 대상**
WaferGuard	Adam · 사전학습	CNN + Sigmoid 분류기
Transfer Stage 1	Adam · 1e-3	Dense Head만 학습
Transfer Stage 2	Adam · 1e-5	마지막 Conv 2개 + Dense
WM-811K Baseline	Adam · 1e-3	CNN 전체 학습

WM-811K: batch size 64 · 최대 25 epochs · class weight · EarlyStopping / best validation loss

WaferGuard → WM-811K | Zero-shot **평가**

Test Accuracy

30.63%

WM-811K 7,894개

Macro F1

24.91%

8개 결함 평균

해석

WaferGuard에서 학습한 특징만으로는 WM-811K의 결함 분포를 충분히 분류하지 못함

- Near-full Recall 85.26%
- Edge-Loc Recall 59.81%
- Scratch Recall 0.14%
- Random 예측 쏠림 / 낮은 Precision

Zero-shot**은 추가 학습이 없다는 뜻이며, 두 데이터셋 간 이미지 중복 가능성은 별도 검증 필요**

Stage 1 → Stage 2 | **적응 학습 성능**

Zero-shot

30.63%

WaferGuard CNN 직접 예측

Stage 1

59.18%

분류기만 학습 · +28.55%p

Stage 2

63.90%

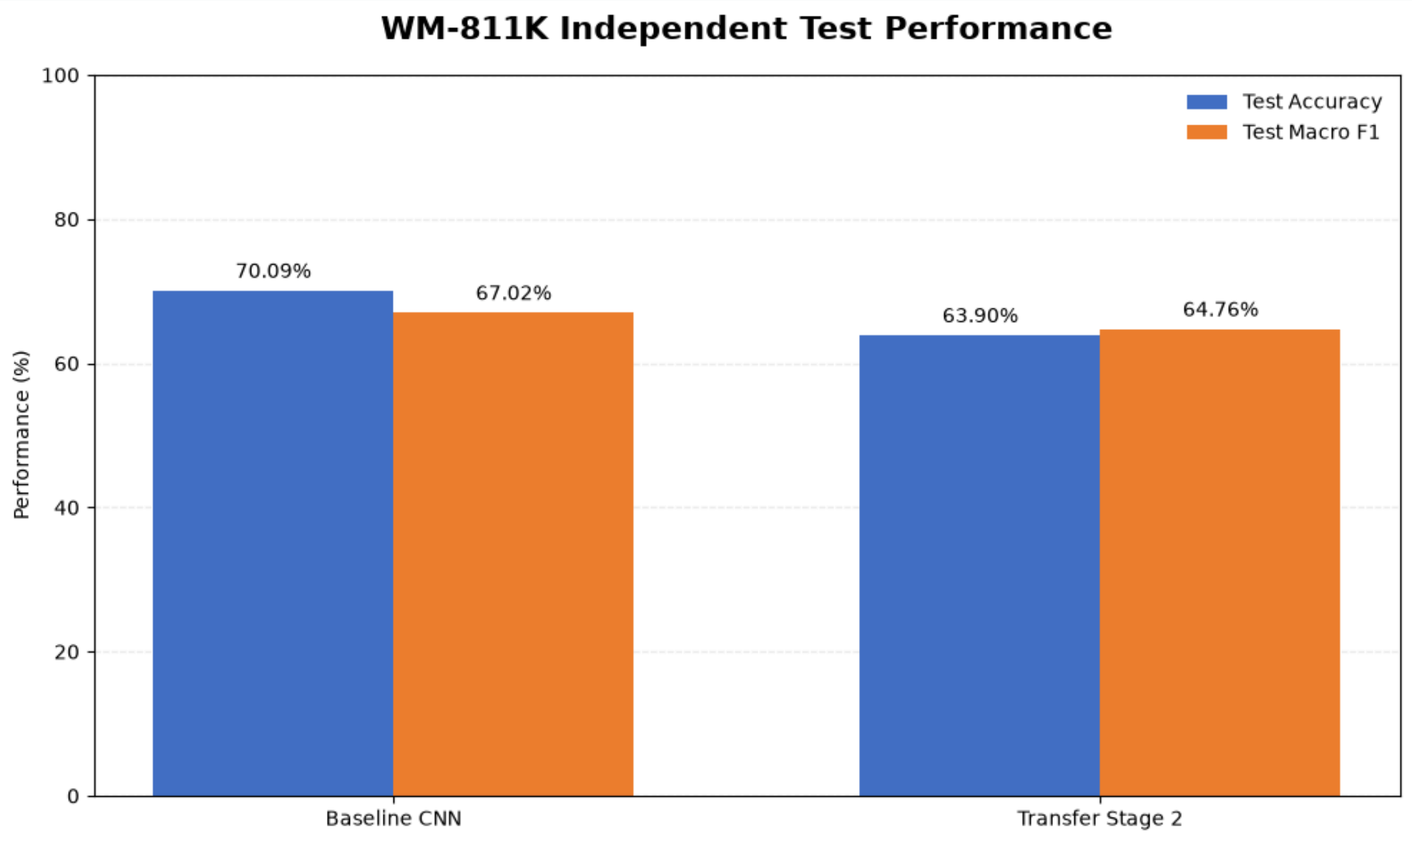
Conv Fine-tuning · +4.72%p

전체 향상: Zero-shot 30.63% → Stage 2 63.90% (+33.27%p)

WM-811K **적응 학습이 성능을 개선했지만, 사전학습 자체의 우월성을 뜻하지는 않음**

Independent Test | Baseline vs Transfer Stage 2

Notebook 원본 성능 비교 그래프



Baseline Accuracy

70.09%

WM-811K 단독 학습

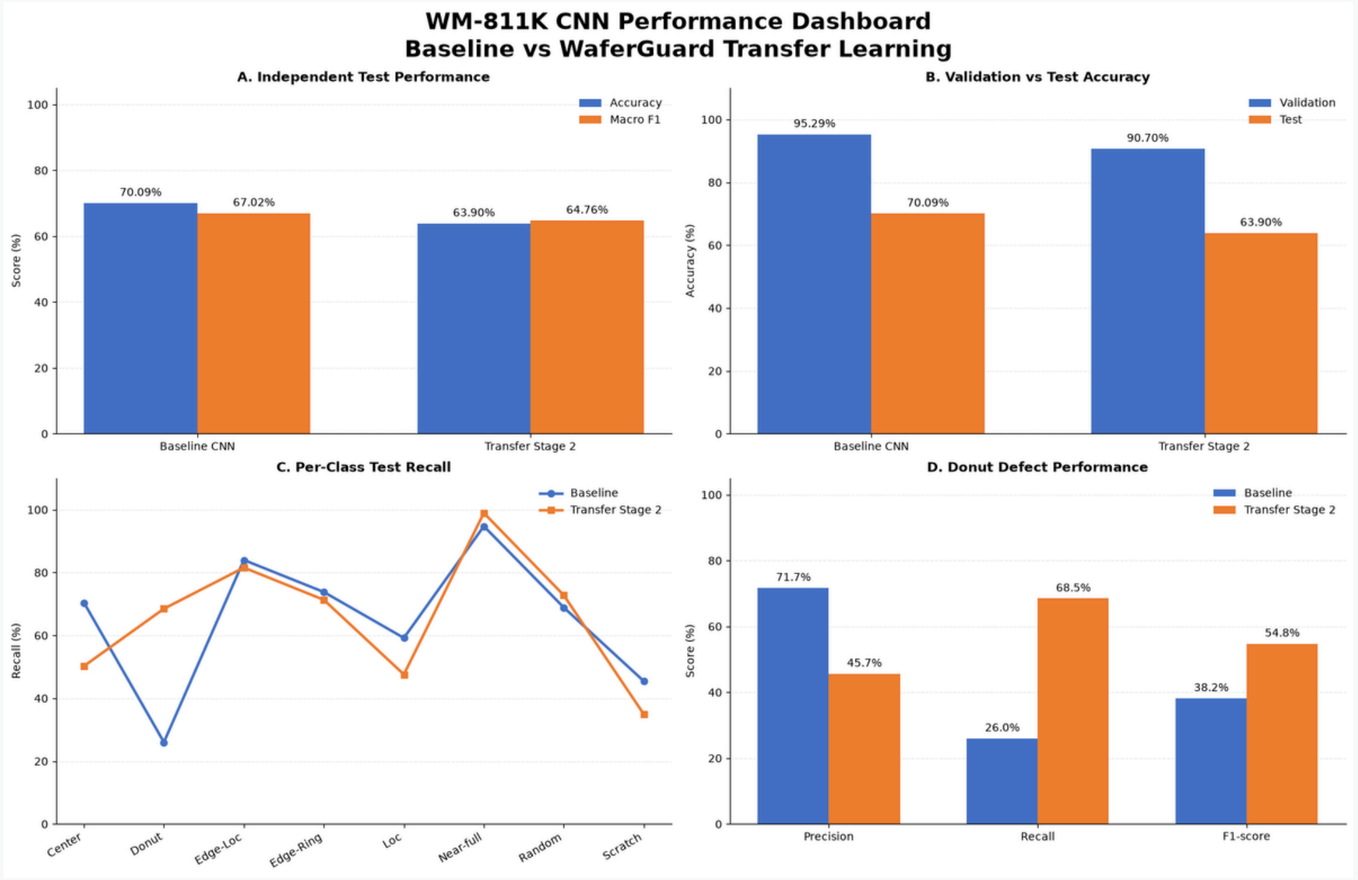
Transfer Accuracy

63.90%

Baseline 대비 -6.19%p

전체 정확도는 Baseline **우위, 그러나 결함 유형별로 전이학습의 장단점이 다름**

Validation vs Test | **일반화 성능 차이**



Accuracy Gap

Baseline

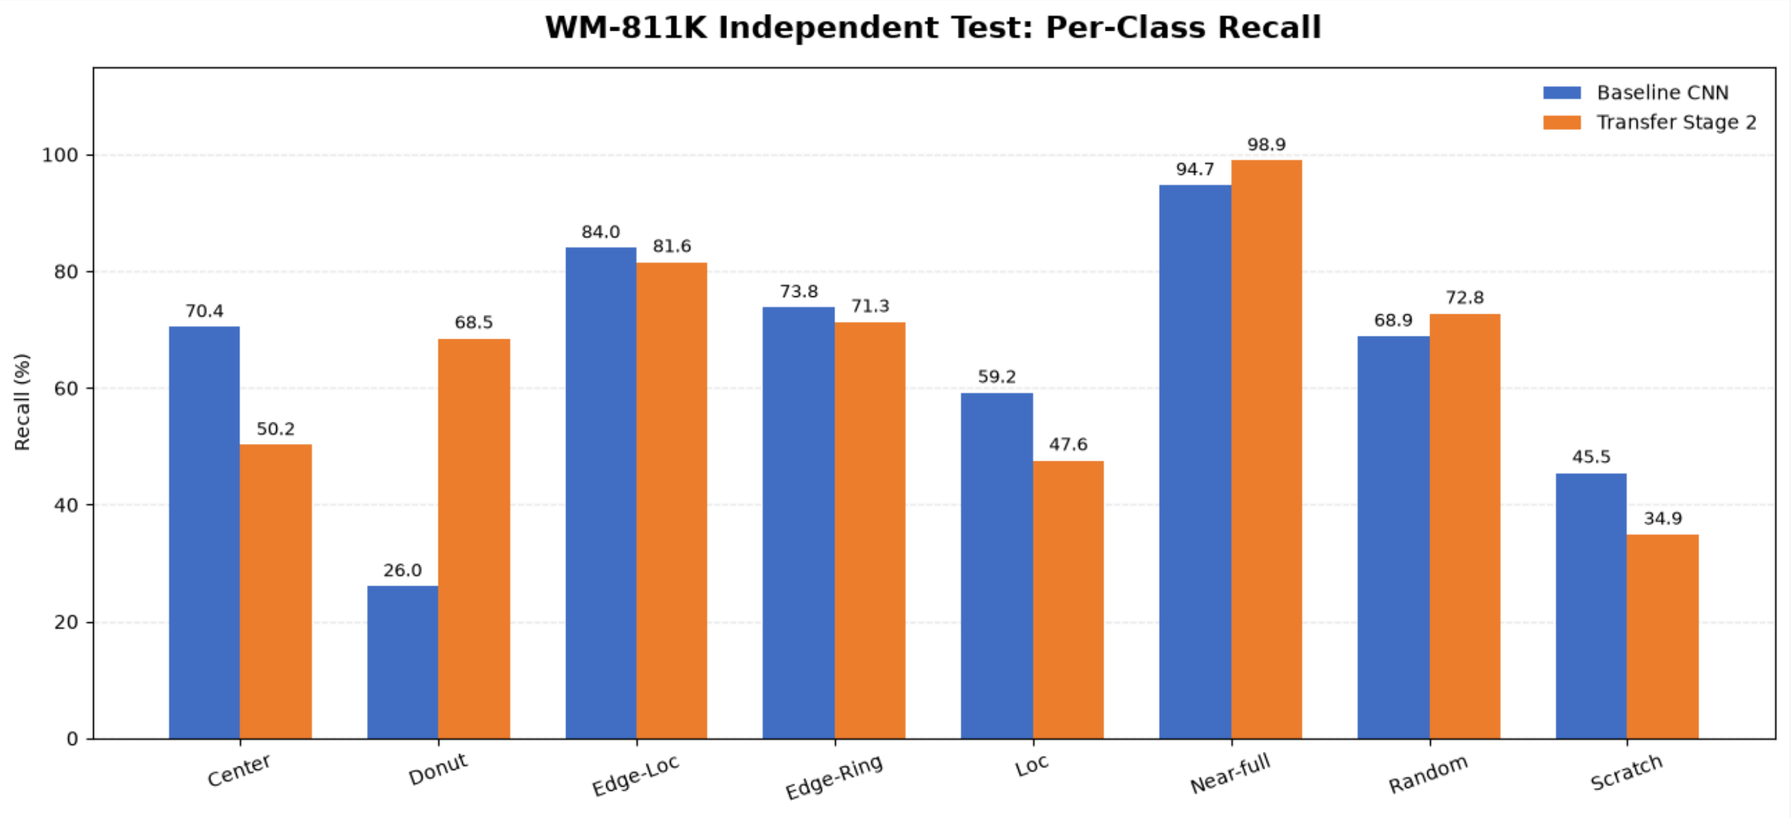
95.29% → 70.09%

Transfer Stage 2

90.70% → 63.90%

학습/검증과 독립 Test 간 분포 차이 가능성: 성능 하락 원인을 단일 요인으로 확정할 수 없음

Class-wise Recall | **결함 유형별 변화**



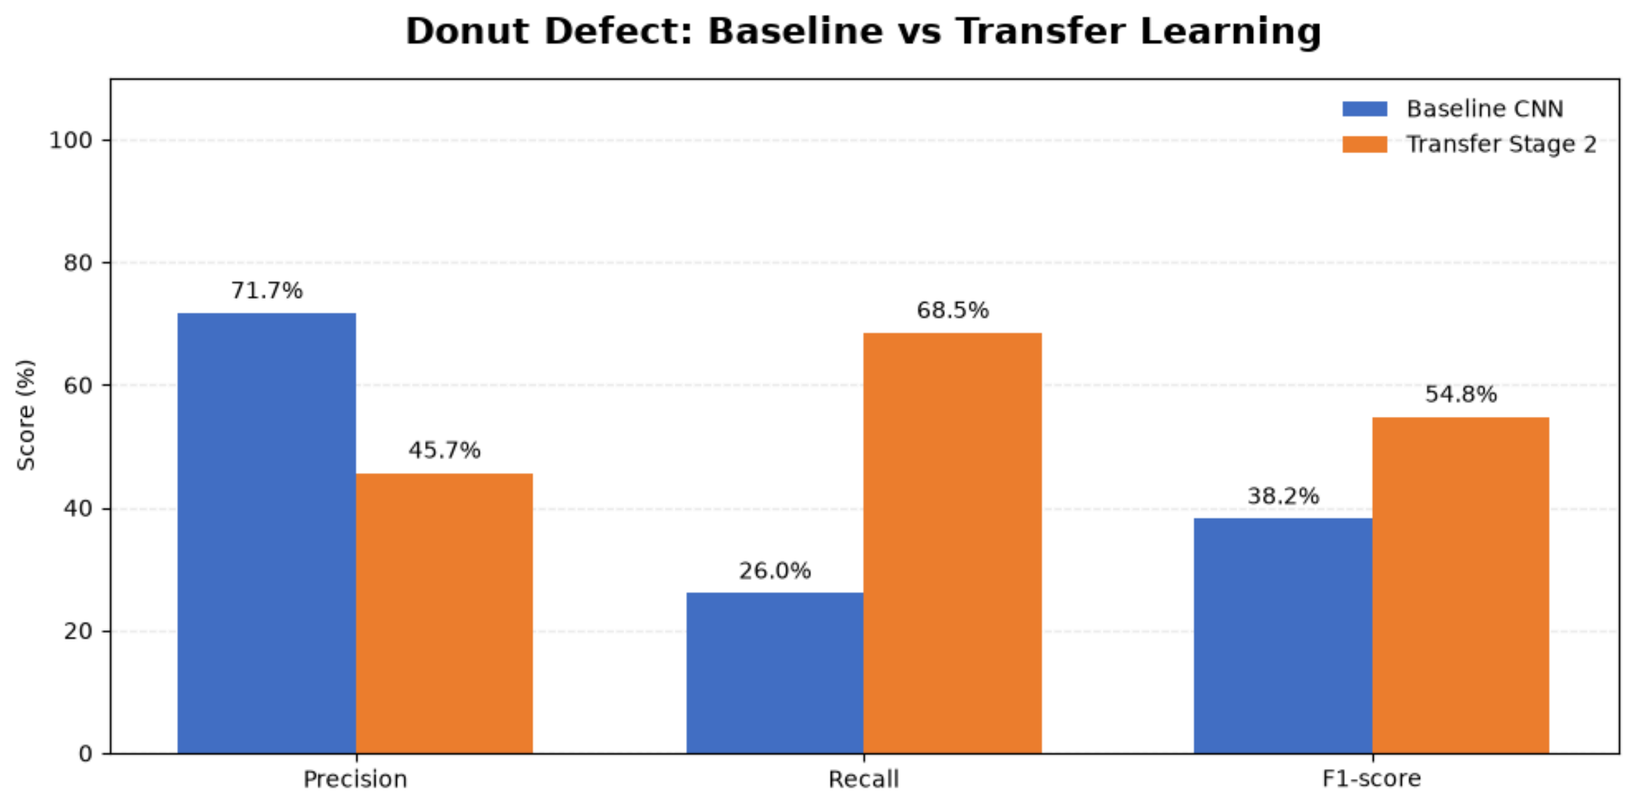
Transfer**는** Donut · Near-full · Random**에서** Recall **개선**, Center · Loc · Scratch**에서 감소**

Class-wise Recall | **결함 유형별 변화** - CNN **학습에 사용한** 811k**의** data

결함 유형	Training	Validation	Test	전체
Center	2,770	692	832	4,294
Donut	327	82	146	555
Edge-Loc	1,933	484	2,772	5,189
Edge-Ring	6,843	1,711	1,126	9,680
Loc	1,296	324	1,973	3,593
Near-full	44	10	95	149
Random	487	122	257	866
Scratch	400	100	693	1,193
합계	14,100	3,525	7,894	25,519

Transfer**는** Donut · Near-full · Random**에서** Recall **개선**, baseline **모델이** data sample**이 작았던 부분에서 확실히 취약한 점을 보였음, 해당 부분이 개선됨**.

Donut Defect | **전이학습의 선택적 이점**



Donut Recall

26.03%

↓ +42.47%p

68.49%

Precision은 하락: 재현율과 정밀도의 trade-off

전체 정확도가 낮더라도 특정 결함 검출 관점에서는 전이학습이 유리할 수 있음

WM-811K Baseline → WaferGuard | **교차 데이터셋 평가**

WM-811K만 학습한 Softmax CNN을 WaferGuard에 추가 학습 없이 적용

Single-label Accuracy

79.59%

단일 결함 7,015개

Single-label Macro F1

80.00%

8개 클래스 평균

Multi Top-1 Hit

79.62%

복합 결함 30,000개

단일 결함: **정답 1개와** argmax **예측 비교**

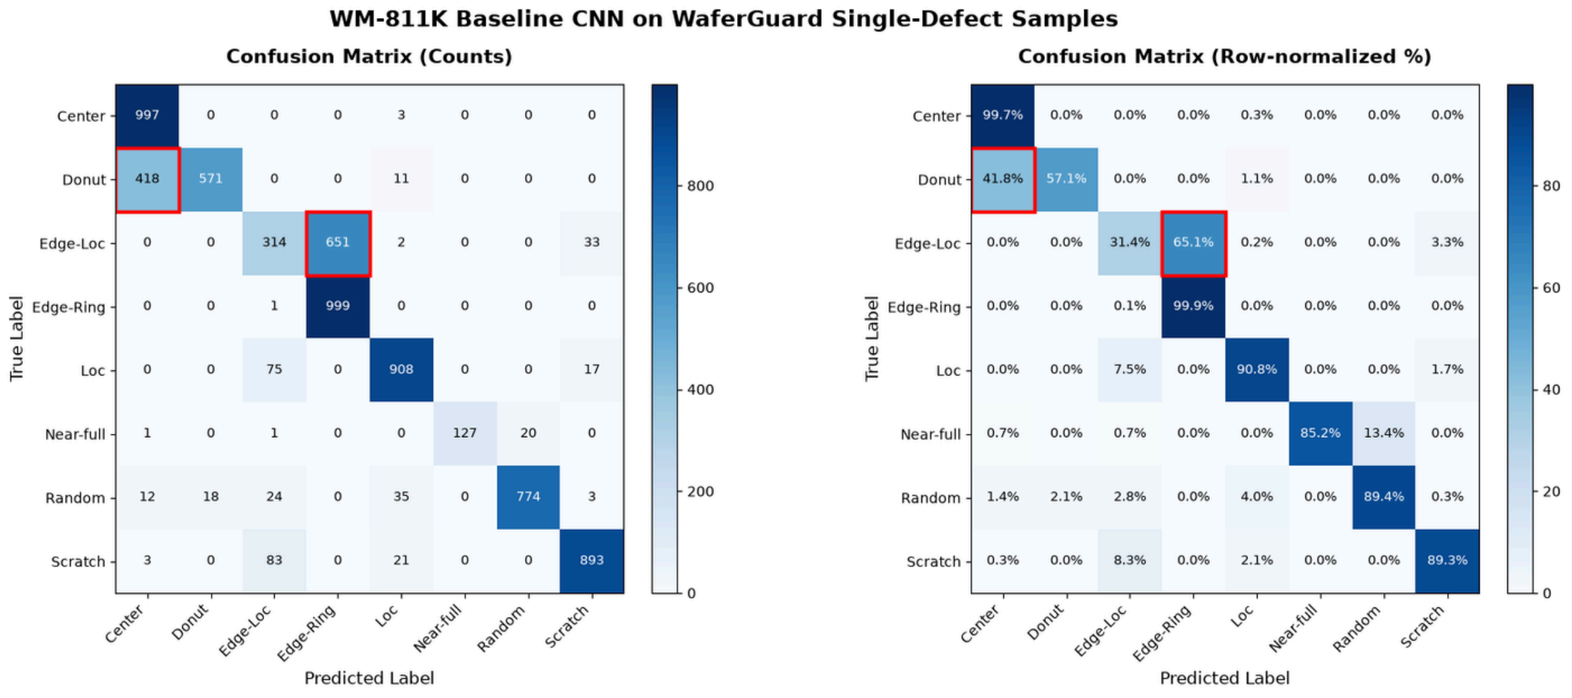
복합 결함: 모델이 선택한 1개 결함이 정답 집합에 포함되면 Hit (정확도와 직접 비교 불가) - 그래서 학습이 되지 않은 데이터셋인 waferguard에 대해서도 높은 Accuracy (멀티라벨 중 하나만 맞춰도 Hit)

라벨 0개인 1,000개는 8-class 모델에 Normal 출력이 없어 평가에서 제외

이 실험은 반대 방향의 Zero-shot **탐색**; WaferGuard **학습 모델의** WM-811K Zero-shot(30.63%)**과 평가 구성이 다름**

WaferGuard | Baseline **오분류 분석**

WM-811K Baseline으로 WaferGuard 단일 결함을 분류한 결과



대표적인 오분류

Donut → Center

418 / 1,000

Edge-Loc → Edge-Ring

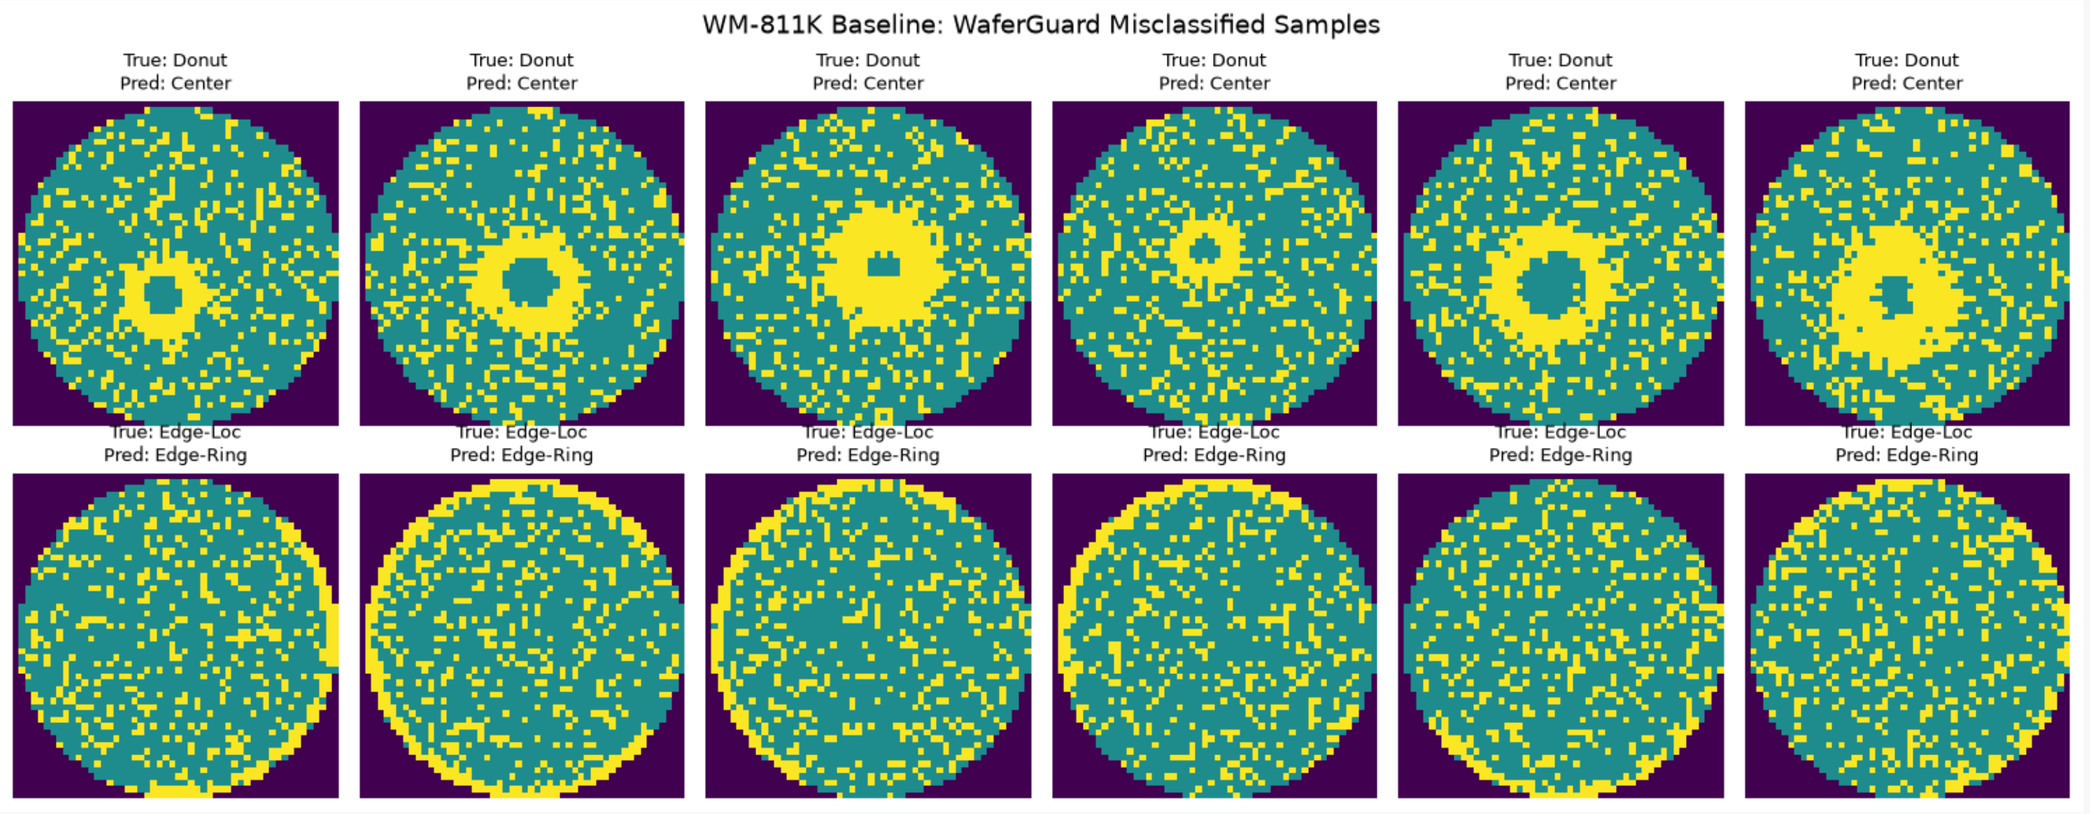
651 / 1,000

서로 다른 데이터셋에서 유사한 공간 패턴이 혼동될 수 있음

해석 주의: WaferGuard **전체 데이터 평가이며, 합성/원본 중복 가능성 때문에 완전 독립 일반화 증거는 아님**

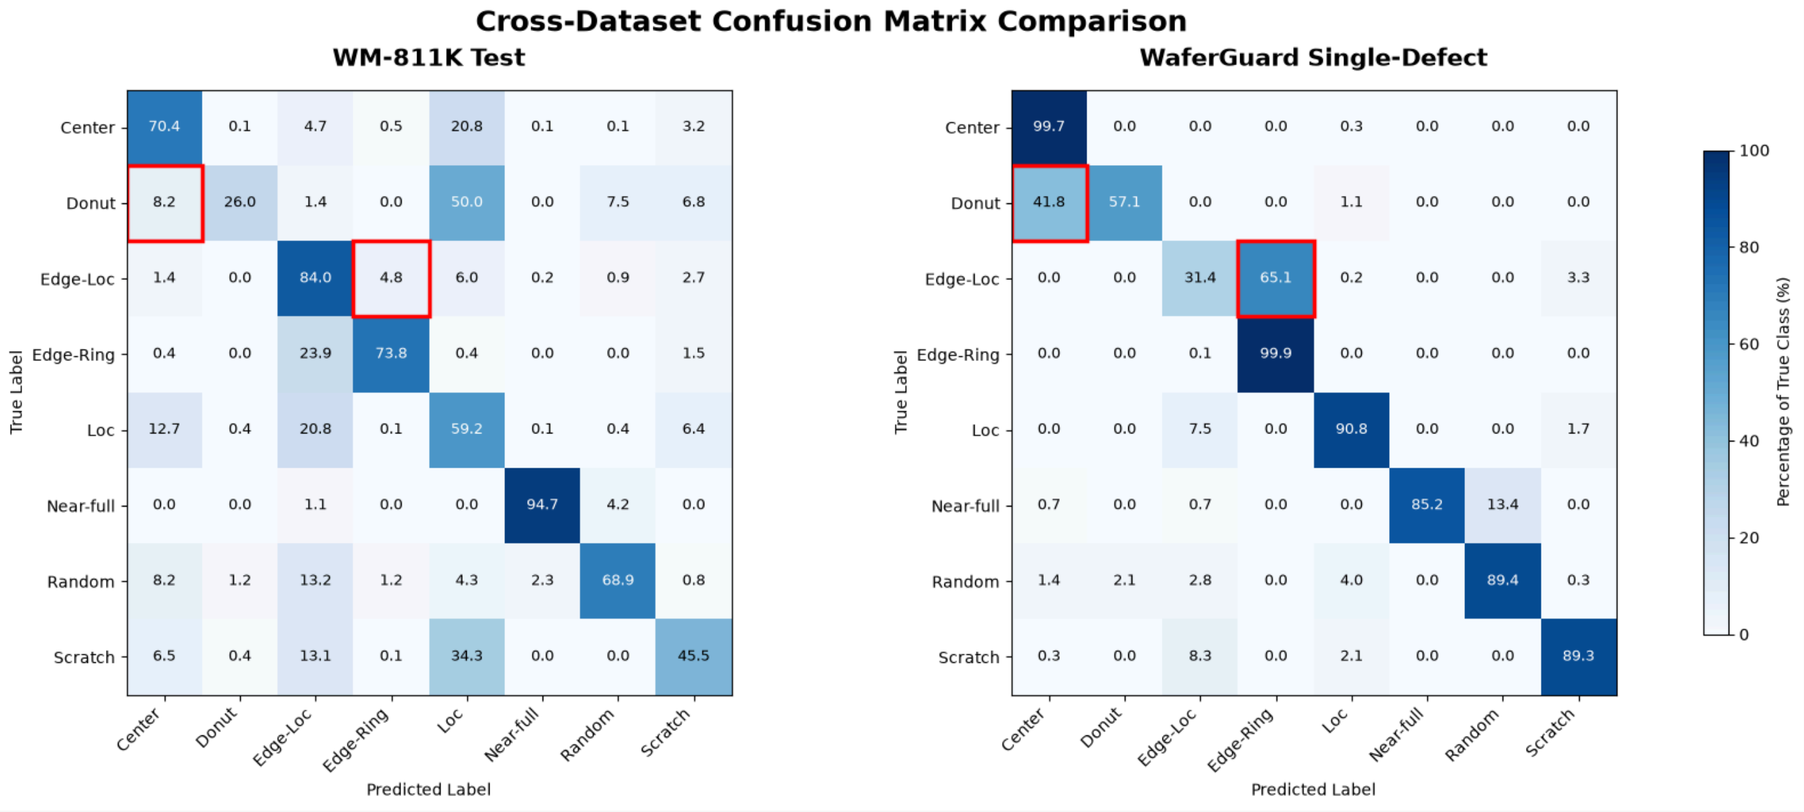
WM-811K Baseline → WaferGuard | **실제 오분류 사례**

평가 모델: WM-811K Baseline CNN | 평가 데이터: WaferGuard 단일 결함 이미지 7,015개



WM-811K Baseline**의** WaferGuard **예측 오류**: Donut → Center / Edge-Loc → Edge-Ring **· 재학습 없는 교차 데이터셋 평가**

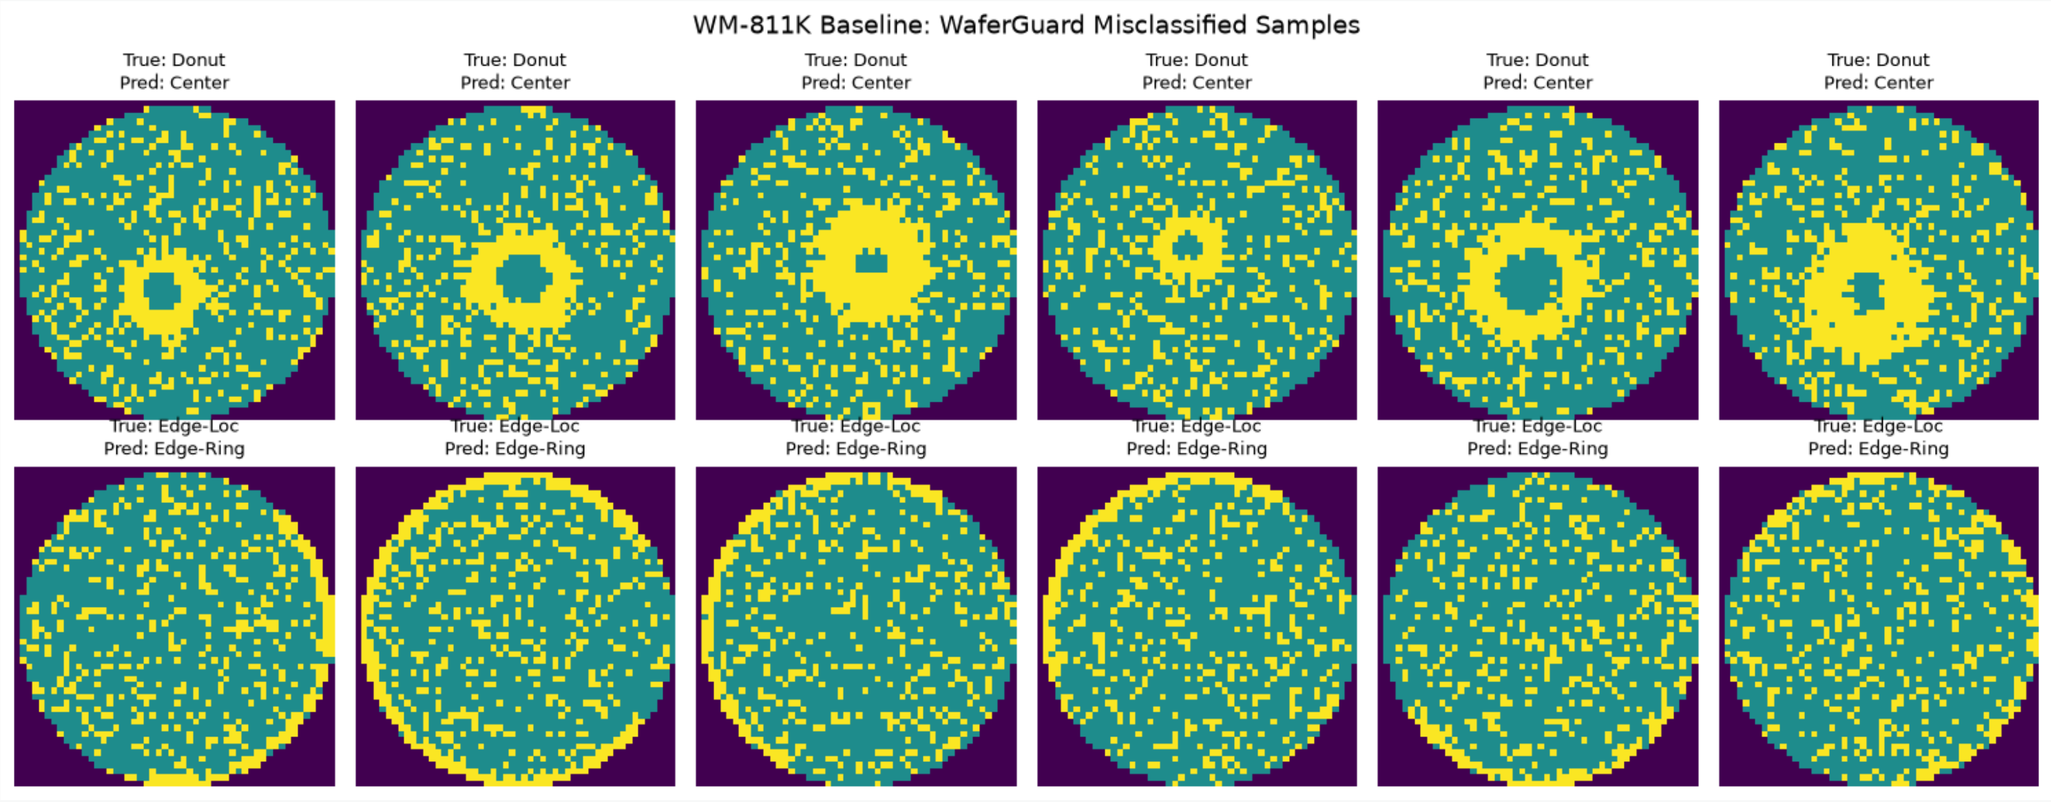
Cross-dataset | 혼동행렬과 패턴 차이



WaferGuard와 WM-811K에서 혼동되는 패턴이 다름 — 데이터셋 간 도메인 차이의 정성적 단서

Error Cases | **평가 모델과 데이터 출처**

WM-811K Baseline CNN → WaferGuard 단일 결함 샘플 (추가 학습 없음)



동일한 WaferGuard **오분류 이미지 재제시** · Donut → Center / Edge-Loc → Edge-Ring

Limitations & Interpretation Rules

데이터셋 차이	Multi-label vs Single-label, 원본 이미지 크기 및 클래스 비율 차이
평가 데이터	원본 WM-811K Test 7,894개 유지; WaferGuard와 원본 중복 여부 미확인
일반화 격차	Validation과 독립 Test 간 25~27%p Accuracy 차이
인과 해석	성능 향상은 WM-811K 추가 학습 효과; 사전학습 우월성의 직접 증거는 아님
공정 원인	Wafer Map 패턴만으로 특정 공정/장비 불량을 확정할 수 없음

공정 Root Cause**는 가설이며, 막 두께·식각률·장비 로그 등 추가 데이터로 검증 필요**

Conclusion | **전이학습의 적응 효과와 한계**

WaferGuard **기반** CNN**은** WM-811K **추가 학습을 통해** 30.63% → 63.90%**로 개선**

- 분류기 학습(Stage 1)과 Conv Fine-tuning(Stage 2) 모두 성능 향상에 기여
- 다른 데이터셋에서 출발한 모델의 목표 도메인 적응 가능성 확인
- Baseline 70.09%에는 미달: 사전학습이 항상 유리한 것은 아님
- Donut Recall은 26.03% → 68.49%로 개선: 결함별 선택적 이점 확인
- Waferguard 데이터셋으로 사전 학습한 모델의 경우, 멀티 라벨도 예측하도록 설계해서 더 낮은 Accuracy를 보였음으로 추정

최종 메시지: **전이학습은 목표 데이터셋 적응에 효과적이었지만**, Baseline **대비 우위는 입증되지 않음** - baseline**과 더 정확히 동일한 환경(멀티 라벨인지 싱글 라벨인지) 에서 비교 필요함**

References & Dataset Attribution

WaferGuard 배포 경로와 원천 데이터·연구 논문을 구분하여 표기

WaferGuard · **사용한 데이터 배포처**

Hugging Face Datasets — oliversinn/waferguard-dataset

https://huggingface.co/datasets/oliversinn/waferguard-dataset

원천 데이터 · MixedWM38 / WaferMap

Junliangwangdhu/WaferMap · 38종 단일/복합 패턴

https://github.com/Junliangwangdhu/WaferMap

원 연구 논문

Wang, J. et al. (2020), Deformable Convolutional Networks for Efficient Mixed-type Wafer Defect Pattern Recognition

DOI: 10.1109/TSM.2020.3020985

원천 자료 / 라이선스

Hugging Face 데이터 카드: Kaggle 원천·라벨 보정 기여자 명시 · CC BY 4.0

https://huggingface.co/datasets/oliversinn/waferguard-dataset/blob/main/README.md

실험 근거: **사용자 제공** Jupyter Notebook · WM-811K **원본** pkl · TensorFlow/Keras **실행 결과**