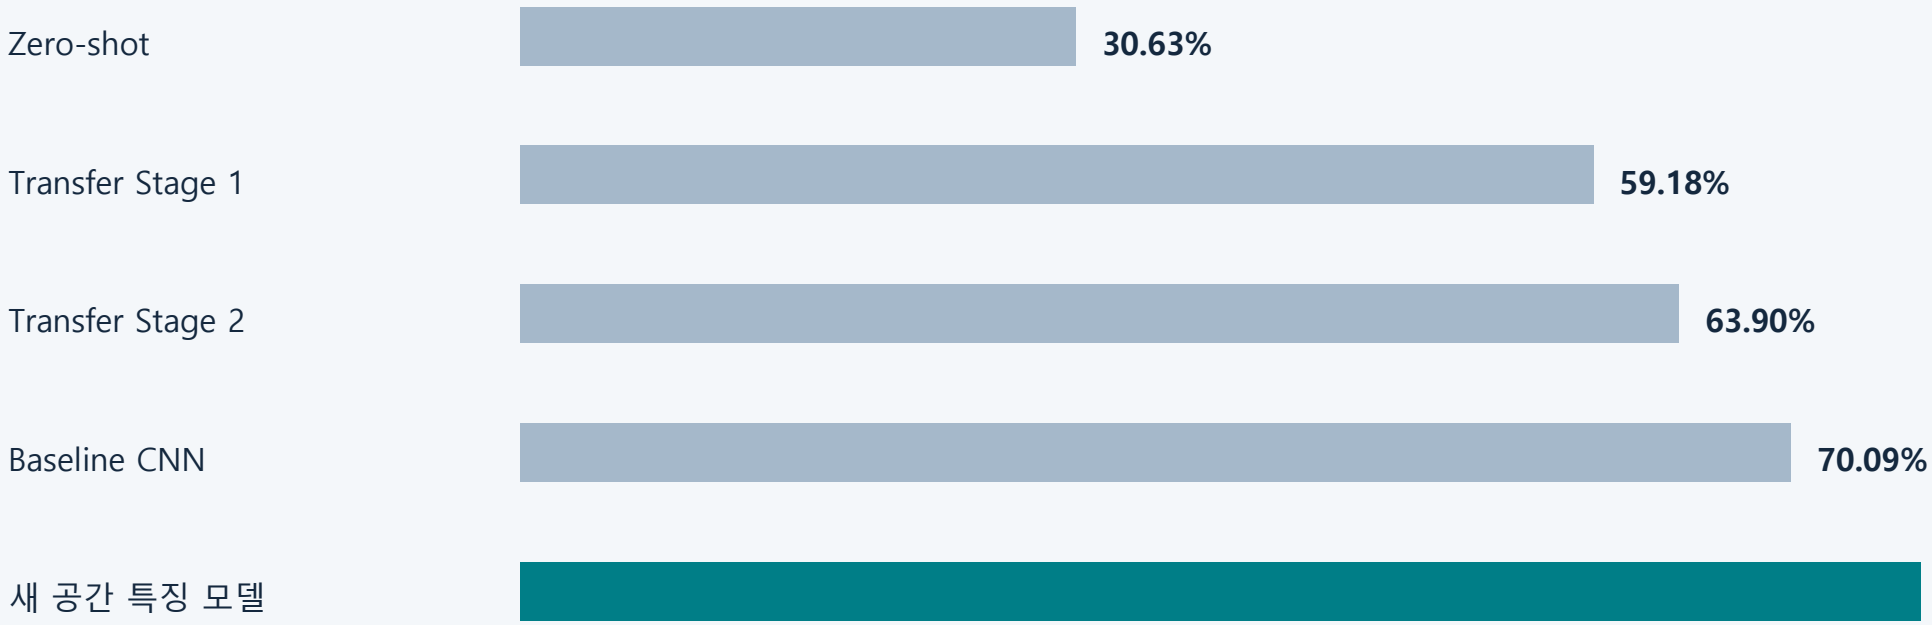
새 모델 정확도 77.24%, 기존 CNN 대비 +7.15%p

원본 Test 7,894장 · 8종 단일 결함 분류 · 새 모델은 공간 특징 + HistGradientBoosting



새 모델 Macro F1 77.67% · Weighted F1 77.43% · Balanced accuracy(평균 재현율) 78.57%

비교 조건: 원본 Training 17,625장 / Test 7,894장. 정상(none)과 무라벨은 제외했다. 기존 모델은 PDF 보고값, 새 모델은 저장된 예측으로 계산했다.

기존 체크포인트·개별 예측이 없어 기존 모델의 F1, 유의성 검정, 추론 속도는 재계산하지 않았다. 성능 향상을 이 테스트 밖의 신규 장비·공장까지 입증한 결과로 해석할 수 없다.

결함별 재현율: 기존 CNN 대비 8종 모두 향상

재현율 = 실제 해당 결함 중 맞힌 비율 · 기존 값은 PDF p.35 그래프의 소수 첫째 자리 표시값

결함	기존 CNN	전이 Stage 2	새 모델	CNN 대비	Test 수
Center	70.4%	50.2%	76.20%	+5.8%p	832
Donut	26.0%	68.5%	80.82%	+54.8%p	146
Edge-Loc	84.0%	81.6%	87.70%	+3.7%p	2772
Edge-Ring	73.8%	71.3%	81.44%	+7.6%p	1126
Loc	59.2%	47.6%	63.30%	+4.1%p	1973
Near-full	94.7%	98.9%	95.79%	+1.1%p	95
Random	68.9%	72.8%	77.04%	+8.1%p	257
Scratch	45.5%	34.9%	66.23%	+20.7%p	693

Donut은 기존 CNN 대비 약 +54.8%p, Scratch는 약 +20.7%p 개선했다. Near-full은 새 모델 95.79%로, 전이학습 98.9%보다 약 3.1%p 낮다.

위 차이는 그래프의 반올림 수치를 사용한 근사치다. PDF p.37의 Donut 상세값은 CNN 26.03%, 전이 68.49%다. 기존 모델의 결함별 Precision/F1은 자료에 없어 새 모델과 직접 비교하지 않았다.

남은 오류는 Loc·Scratch와 국소 결함 혼동에 집중

새 모델 Test의 Precision / Recall / F1 및 혼동행렬로 다음 실험 우선순위를 결정

결함	Precision	Recall	F1	정답 수 / 전체
Center	83.97%	76.20%	79.90%	634 / 832
Donut	62.43%	80.82%	70.45%	118 / 146
Edge-Loc	81.99%	87.70%	84.75%	2431 / 2772
Edge-Ring	91.15%	81.44%	86.02%	917 / 1126
Loc	73.21%	63.30%	67.90%	1249 / 1973
Near-full	94.79%	95.79%	95.29%	91 / 95
Random	85.34%	77.04%	80.98%	198 / 257
Scratch	48.57%	66.23%	56.04%	459 / 693

주요 혼동: Loc → Scratch 311장 · Loc → Edge-Loc 251장 · Edge-Ring → Edge-Loc 185장 · Scratch → Loc 181장

Scratch 정밀도는 48.57%다. Scratch 예측의 절반 이상이 다른 결함이므로 재현율만 높이는 가중치 적용은 신중하게 검증해야 한다.

일반화 격차는 줄었지만 원인은 아직 확정되지 않음

검증과 Test는 서로 다른 표본 · 기존 모델과 새 모델의 내부 검증 분할도 완전히 같다고 확인할 수 없음

모델	검증 정확도	Test 정확도	차이
기존 CNN	95.29%	70.09%	25.20%p
전이 Stage 2	90.70%	63.90%	26.80%p
새 모델	96.96%	77.24%	19.73%p

확인된 사실

- Training과 Test의 중복 lotName은 0개다. 동일 픽셀 맵은 Test 92장에 존재하며, 이를 제외한 7,802장의 정확도는 77.01%다.
- Training의 Edge-Ring 비율은 48.53%, Test는 14.26%다. 반대로 Loc은 9.19% → 24.99%, Scratch는 2.84% → 8.78%다. 클래스 비율 변화가 전체 정확도에 영향을 줄 수 있다.
- 검증은 5개 fold 중 첫 fold만 사용했다. 단일 검증의 96.96%가 신규 로트 전반의 성능을 대표한다고 단정할 수 없다.

가설: 클래스 비율 차이 외에 맵 크기·결함 밀도·로트별 패턴 차이가 영향을 줄 수 있다. 과적합과 분포 변화의 기여도는 별도 진단 실험이 필요하다.

일반화 개선은 검증 설계와 취약 패턴 보강부터

아래는 후속 실험 제안이며, 개선 효과를 아직 측정한 결과는 아님

우선순위	구체적 방법	기대 효과와 판단 기준
1 · 검증 강화	원본 Training에서 로트 독립 5-fold 전체 평가. 로트와 동일·회전 맵 그룹을 함께 분리. 신규 수집 로트는 별도 최종 평가용으로 확보.	평균·표준편차·최저 fold Accuracy와 Macro F1을 보고, 단일 fold에만 좋은 모델을 피한다. 검증 강화 자체가 정확도를 올리는 것은 아니다.
2 · Scratch / Loc 특징	결함 좌표의 직선성, Hough/Radon 응답, 연결 군집 길이·폭·방향 일관성을 추가. 군집 밀도와 반경 위치를 함께 사용.	Loc → Scratch 오탐을 줄이는지 확인. Scratch Precision/F1 및 Loc Recall을 동시에 평가한다.
3 · 입력 변화 대응	크기 정규화 과정의 샘플링 손실 점검. 원본 좌표 특징과 여러 해상도 특징을 결합. 학습 fold에서만 회전·반전·소량 픽셀 잡음 증강.	회전·맵 크기·결함률 구간별 성능을 비교한다. 증강이 결함 라벨 의미를 유지하는지 샘플 검토한다.
4 · 규제 / 가중치	max_leaf_nodes 7/15/23, l2 3/10, min_samples_leaf 20/50을 작은 탐색으로 비교. 무가중/완만한 클래스·로트 가중을 비교.	복잡도 축소와 불균형 대응은 서로 다른 실험으로 검증. 전체 정확도 상승과 소수 결함 F1 사이의 손익을 기록한다.

실제 운영과 다른 데이터 비율을 Test 정답으로 역산해 학습 가중치에 적용하면 평가가 낙관적으로 변할 수 있다. 가중치는 Training과 별도 검증 설계 안에서 선택한다.

다음 실험의 성공 기준과 비교 근거

추가 학습 전 프로토콜을 고정하고 기존 77.24% 결과를 기준 기록으로 보존

권장 진행 순서

① 현재 특징으로 5-fold 기준선 확보 → ② 직선성·군집 특징 추가 → ③ 규제·가중치 비교 → ④ 증강/다중 해상도 비교. 각 단계에서 변경 요소를 하나씩 평가한다.

채택 기준

동일한 fold·seed에서 평균 Accuracy와 Macro F1, 최저 fold 성능을 함께 비교한다. Scratch Precision과 Loc Recall의 손익을 명시한다. 로트 단위 bootstrap 신뢰구간을 계산하고, 기존 모델 예측이 확보되면 동일 표본의 대응 비교를 추가한다.

평가 데이터 관리

현재 Test 결과는 이미 확인했으므로 향후 실험에 반복 활용하면 개발용 벤치마크가 된다. 최종 일반화 주장은 새로 확보한 비공개 로트·시점·장비 데이터에서 확정한다. 실제 시각/장비 식별자가 없으므로 lotName 순서만으로 시간 분할을 가정하지 않는다.

근거와 제한

[1] 제공 PDF p.27~34: 분할, 학습 조건, 전체 성능 및 검증/Test 차이. p.35·37: 결함별 재현율.

[2] results/evaluation.json, test_predictions.csv, train_spatial.py: 새 모델 실측값·혼동행렬·선택 절차.

[3] scikit-learn 공식 문서: 그룹 교차검증과 표본 가중치. 아래 링크는 방법 설명의 근거이며 WM-811K 개선 효과를 보장하지 않는다.

그룹 교차검증

표본 가중치